

RegresionLineal

July 18, 2026

Programa12.Regresion.OLS (1)

July 16, 2026

PAO25-25 - REGRESIÓN LINEAL

Kevin Suasnavas

Link a GitHub:

<https://github.com/kevinsuas433/Machine2026.git>

1 1. Importación de librerías

En esta sección se importan las librerías necesarias para desarrollar el modelo de regresión lineal. Estas bibliotecas permiten realizar operaciones matemáticas, cargar conjuntos de datos, entrenar el modelo, evaluar su rendimiento y visualizar los resultados obtenidos.

```
[1]: # =====  
# IMPORTACIÓN DE LIBRERÍAS  
# =====  
  
# NumPy permite trabajar con arreglos y realizar operaciones  
# matemáticas de forma eficiente.  
import numpy as np  
  
# Se importa la función sqrt para calcular la raíz cuadrada.  
from math import sqrt  
  
# pprint permite imprimir estructuras de datos de manera  
# organizada y fácil de leer.  
from pprint import pprint  
  
# Se importan los módulos necesarios de Scikit-Learn para  
# cargar datos, construir modelos de regresión y evaluar  
# su desempeño.  
from sklearn import datasets, linear_model, metrics  
  
# Modelo de referencia (baseline) utilizado para comparar
```

```

# el rendimiento del modelo de regresión.
from sklearn.dummy import DummyRegressor

# Herramientas para dividir los datos y realizar
# validación cruzada.
from sklearn.model_selection import (
    cross_validate,
    KFold,
    cross_val_predict,
    train_test_split,
    cross_val_score
)

# Librería utilizada para estandarizar las variables
# antes del entrenamiento del modelo.
from sklearn import preprocessing

# Funciones para crear métricas personalizadas
# y calcular el error cuadrático medio.
from sklearn.metrics import make_scorer, mean_squared_error

# Matplotlib permite generar gráficos para visualizar
# los resultados del modelo.
import matplotlib.pyplot as plt

```

2 2. Carga del conjunto de datos

En esta práctica se utiliza el conjunto de datos **California Housing**, disponible en Scikit-Learn. Este conjunto contiene información sobre viviendas en California y será utilizado para entrenar y evaluar el modelo de regresión lineal.

```

[3]: # =====
# CARGA DEL CONJUNTO DE DATOS
# =====

# Se carga el conjunto de datos California Housing.
datos = datasets.fetch_california_housing()

# Variables independientes (características).
X = datos.data

# Variable objetivo.
y = datos.target

# Se muestran las dimensiones del conjunto de datos.
print("Dimensiones de X:", np.shape(X))

```

Dimensiones de X: (20640, 8)

3 3. Definición de métricas de evaluación

Para evaluar el desempeño del modelo de regresión se definen varias métricas que serán utilizadas durante la validación cruzada.

- **MAE:** Error Absoluto Medio.
- **RMSE:** Raíz del Error Cuadrático Medio.
- **MAPE:** Error Porcentual Absoluto Medio.
- **R²:** Coeficiente de Determinación.

```
[4]: # =====  
# MÉTRICAS DE EVALUACIÓN  
# =====  
  
# Se define un diccionario con las métricas que serán  
# utilizadas para evaluar el modelo durante la  
# validación cruzada.  
metricas = {  
  
    # Error Absoluto Medio (Mean Absolute Error)  
    'MAE': 'neg_mean_absolute_error',  
  
    # Raíz del Error Cuadrático Medio (Root Mean Squared Error)  
    'RMSE': make_scorer(  
        lambda y, y_pred: sqrt(metrics.mean_squared_error(y, y_pred)),  
        greater_is_better=False  
    ),  
  
    # Error Porcentual Absoluto Medio  
    'MAPE': make_scorer(  
        lambda y, y_pred: np.mean(np.abs((y - y_pred) / y)) * 100,  
        greater_is_better=False  
    ),  
  
    # Coeficiente de Determinación  
    'R2': 'r2'  
}
```

4 4. Partición del conjunto de datos

En esta etapa el conjunto de datos se divide en dos subconjuntos:

- **Datos de entrenamiento (80%),** utilizados para entrenar el modelo.
- **Datos de prueba (20%),** utilizados para evaluar el desempeño del modelo con información que no fue utilizada durante el entrenamiento.

Esta separación permite medir la capacidad de generalización del algoritmo.

```
[5]: # =====
# PARTICIÓN DEL CONJUNTO DE DATOS
# =====

# Se divide el conjunto de datos en entrenamiento (80%)
# y prueba (20%).
X_training, X_testing, y_training, y_testing = train_test_split(
    X,
    y,
    test_size=0.20,
    random_state=42
)

# Se muestra el tamaño del conjunto de entrenamiento.
print("Dimensiones de X_training:", np.shape(X_training))
```

Dimensiones de X_training: (16512, 8)

5 5. Estandarización de los datos

Antes de entrenar el modelo es recomendable estandarizar las variables de entrada para que todas tengan una escala similar.

La estandarización transforma cada característica para que tenga una media cercana a cero y una desviación estándar igual a uno, mejorando la estabilidad del entrenamiento.

```
[6]: # =====
# ESTANDARIZACIÓN DE LOS DATOS
# =====

# Se crea el objeto encargado de estandarizar los datos.
standardizer = preprocessing.StandardScaler()

# Se calculan la media y desviación estándar utilizando
# únicamente los datos de entrenamiento.
stdr_trained = standardizer.fit(X_training)

# Se transforman los datos de entrenamiento.
X_stdr = stdr_trained.transform(X_training)
```

6 6. Construcción del modelo de regresión lineal

En este paso se crea el modelo de Regresión Lineal que aprenderá la relación existente entre las variables predictoras y la variable objetivo.

El parámetro `fit_intercept=True` indica que el modelo calculará automáticamente el término independiente de la ecuación.

```
[7]: # =====
# CONSTRUCCIÓN DEL MODELO
# =====

# Se crea el modelo de Regresión Lineal.
# fit_intercept=True permite calcular el intercepto
# de la recta de regresión.
reg = linear_model.LinearRegression(fit_intercept=True)
```

7 7. Validación cruzada

La validación cruzada permite estimar el desempeño del modelo utilizando diferentes particiones del conjunto de entrenamiento.

En este caso se utiliza una validación cruzada de **5 particiones (5-Fold Cross Validation)** para calcular las métricas de evaluación definidas anteriormente.

```
[8]: # =====
# VALIDACIÓN CRUZADA
# =====

# Se evalúa el modelo mediante validación cruzada
# utilizando cinco particiones (5-Fold).

cross_val_results = cross_validate(
    reg,
    X_stdr,
    y_training,
    cv=KFold(
        n_splits=5,
        shuffle=True,
        random_state=42
    ),
    scoring=metricas
)

# Se muestran todas las métricas obtenidas
# durante la validación cruzada.
pprint(cross_val_results)

{'fit_time': array([0.02606916, 0.00670385, 0.00689054, 0.00725436,
0.00865889]),
 'score_time': array([0.00501013, 0.00439405, 0.01254392, 0.00499058,
0.00385118]),
 'test_MAE': array([-0.54071407, -0.52878981, -0.51274193, -0.53512422,
-0.52793364]),
 'test_MAPE': array([-31.74769388, -31.65516613, -30.97054077, -32.61432353,
-30.685065  ]),
```

```
'test_R2': array([0.60970239, 0.60411343, 0.6354319 , 0.60076148, 0.60727452]),  
'test_RMSE': array([-0.73389779, -0.72516701, -0.69726867, -0.73337185,  
-0.71284225])}
```

8. Entrenamiento del modelo

Una vez validado el algoritmo, el modelo se entrena utilizando todos los datos del conjunto de entrenamiento.

Posteriormente se obtienen los coeficientes de la ecuación de regresión y el término independiente, los cuales describen matemáticamente el modelo aprendido.

```
[9]: # =====  
# ENTRENAMIENTO DEL MODELO  
# =====  
  
# Se entrena el modelo utilizando todos los datos  
# de entrenamiento previamente estandarizados.  
model = reg.fit(X_std, y_training)  
  
# Se obtienen los coeficientes del modelo.  
w = model.coef_  
  
print("Coeficientes del modelo:\n")  
print(w)  
  
# Se obtiene el término independiente (intercepto).  
w_0 = model.intercept_  
  
print("\nTérmino independiente:")  
print(w_0)
```

Coeficientes del modelo:

```
[ 0.85438303  0.12254624 -0.29441013  0.33925949 -0.00230772 -0.0408291  
-0.89692888 -0.86984178]
```

Término independiente:
2.071946937378619

9. Preparación del conjunto de prueba

Antes de realizar las predicciones, el conjunto de datos de prueba debe recibir la misma transformación aplicada al conjunto de entrenamiento.

Para ello, se utiliza el estandarizador entrenado previamente, garantizando que ambas particiones tengan la misma escala y evitando inconsistencias durante la predicción.

```
[10]: # =====
# PREPARACIÓN DEL CONJUNTO DE PRUEBA
# =====

# Se estandarizan los datos del conjunto de prueba utilizando
# el mismo escalador entrenado con los datos de entrenamiento.
# Esto garantiza que ambos conjuntos tengan la misma escala.
X_test_stdr = stdr_trained.transform(X_testing)
```

10. Predicción del modelo

Una vez preparados los datos de prueba, el modelo entrenado realiza las predicciones correspondientes.

El resultado es un conjunto de valores estimados que posteriormente serán comparados con los valores reales para evaluar la calidad del modelo.

```
[11]: # =====
# PREDICCIÓN DEL CONJUNTO DE PRUEBA
# =====

# El modelo realiza la predicción sobre los datos de prueba.
y_pred_test = model.predict(X_test_stdr)
```

11. Evaluación del modelo

Para conocer el rendimiento del modelo se calculan diferentes métricas de evaluación:

- **MAE (Mean Absolute Error):** mide el error absoluto promedio.
- **MSE (Mean Squared Error):** penaliza con mayor peso los errores grandes.
- **RMSE (Root Mean Squared Error):** representa el error promedio en las mismas unidades de la variable objetivo.
- **MAPE (Mean Absolute Percentage Error):** expresa el error promedio en porcentaje.
- **R² (Coeficiente de Determinación):** indica qué tan bien el modelo explica la variabilidad de los datos.

```
[12]: # =====
# CÁLCULO DE LAS MÉTRICAS DE EVALUACIÓN
# =====

# Se calcula el Error Absoluto Medio.
MAE = metrics.mean_absolute_error(y_testing, y_pred_test)

# Se calcula el Error Cuadrático Medio.
MSE = metrics.mean_squared_error(y_testing, y_pred_test)

# Se calcula la Raíz del Error Cuadrático Medio.
RMSE = np.sqrt(MSE)
```

```

# Se calcula el Error Porcentual Absoluto Medio.
MAPE = metrics.mean_absolute_percentage_error(y_testing, y_pred_test)

# Se calcula el Coeficiente de Determinación.
R2 = metrics.r2_score(y_testing, y_pred_test)

# Se muestran los resultados obtenidos.
print(f"MAE : {MAE:.4f}")
print(f"MSE : {MSE:.4f}")
print(f"RMSE : {RMSE:.4f}")
print(f"MAPE : {MAPE:.4f}")
print(f"R2 : {R2:.4f}")

```

```

MAE : 0.5332
MSE : 0.5559
RMSE : 0.7456
MAPE : 0.3195
R2 : 0.5758

```

12. Visualización de resultados

Finalmente, se representa gráficamente la relación entre los valores reales y las predicciones realizadas por el modelo.

Si las predicciones fueran perfectas, todos los puntos se ubicarían sobre la línea diagonal. Cuanto más cerca se encuentren los puntos de dicha línea, mejor será el desempeño del modelo.

```

[13]: # =====
# GRÁFICA DE VALORES REALES VS PREDICCIONES
# =====

# Se crea la figura donde se compararán los valores reales
# con los valores predichos.
fig, ax = plt.subplots(figsize=(8, 6))

# Se dibuja el diagrama de dispersión.
ax.scatter(
    y_testing,
    y_pred_test,
    edgecolors="black"
)

# Se dibuja la línea de referencia ideal.
ax.plot(
    [y.min(), y.max()],
    [y.min(), y.max()],
    "k--",

```



```

        lw=2
    )


    # Etiquetas de los ejes.
    ax.set_xlabel("Valor real")
    ax.set_ylabel("Valor predicho")

    # Título con las métricas obtenidas.
    plt.title(
        f"MAE={MAE:.3f} | "
        f"MSE={MSE:.3f} | "
        f"RMSE={RMSE:.3f} | "
        f"MAPE={MAPE:.3f} | "
        f"R²={R2:.3f}"
    )

    # Se activa la cuadrícula para facilitar la lectura.
    plt.grid(True)

    # Se muestra la gráfica.
    plt.show()

```



[]: